



# 15강: EM Algorithm & Factor Analysis

[EM Algorithm](#)

[Factor Analysis](#)

[Restrictions of  \$\Sigma\$](#)


[Marginals and conditionals of Gaussians](#)

[The Factor analysis model](#)

[파라미터 설명](#)

[Joint Gaussian distribution of  \$z\$  and  \$x\$](#)

## EM Algorithm



다시 한 번 EM 알고리즘을 통해 gaussian mixture 모형의 파라미터를 구해보자 .

1. E-step

:  $w_j^{(i)}$ 를 계산한다.

$$w_j^{(i)} = Q_i(z^{(i)} = j) = P(z^{(i)} = j | x^{(i)}; \phi, \mu, \Sigma)$$

$Q_i(z^{(i)} = j)$ 는  $Q$ 분포 하에서  $z^{(i)}$ 의 확률을 나타낸다.

## 2. M-step

:  $\phi, \mu, \Sigma$ 에 대해서 다음을 maximize해야한다.

$$\begin{aligned} & \sum_{i=1}^n \sum_{z^{(i)}} Q_i(z^{(i)}) \log \frac{p(x^{(i)}, z^{(i)}; \phi, \mu, \Sigma)}{Q_i(z^{(i)})} \\ &= \sum_{i=1}^n \sum_{j=1}^k Q_i(z^{(i)} = j) \log \frac{p(x^{(i)} | z^{(i)} = j; \mu, \Sigma) p(z^{(i)} = j; \phi)}{Q_i(z^{(i)} = j)} \\ &= \sum_{i=1}^n \sum_{j=1}^k w_j^{(i)} \log \frac{\frac{1}{(2\pi)^{d/2} |\Sigma_j|^{1/2}} \exp\left(-\frac{1}{2}(x^{(i)} - \mu_j)^T \Sigma_j^{-1} (x^{(i)} - \mu_j)\right) \cdot \phi_j}{w_j^{(i)}} \end{aligned}$$

다음과 같은 식을 각각의 파라미터에 대해 미분하고 0이 되는 값을 찾으면 된다.

- $\mu_1$ 에 대해서 최대화

$$\begin{aligned} & \nabla_{\mu_l} \sum_{i=1}^n \sum_{j=1}^k w_j^{(i)} \log \frac{\frac{1}{(2\pi)^{d/2} |\Sigma_j|^{1/2}} \exp\left(-\frac{1}{2}(x^{(i)} - \mu_j)^T \Sigma_j^{-1} (x^{(i)} - \mu_j)\right) \cdot \phi_j}{w_j^{(i)}} \\ &= -\nabla_{\mu_l} \sum_{i=1}^n \sum_{j=1}^k w_j^{(i)} \frac{1}{2} (x^{(i)} - \mu_j)^T \Sigma_j^{-1} (x^{(i)} - \mu_j) \\ &= \frac{1}{2} \sum_{i=1}^n w_l^{(i)} \nabla_{\mu_l} 2\mu_l^T \Sigma_l^{-1} x^{(i)} - \mu_l^T \Sigma_l^{-1} \mu_l \\ &= \sum_{i=1}^n w_l^{(i)} (\Sigma_l^{-1} x^{(i)} - \Sigma_l^{-1} \mu_l) \end{aligned}$$

위 식을 0으로 두고  $\mu_1$ 에 대해서 풀면 다음과 같다.

$$\mu_l := \frac{\sum_{i=1}^n w_l^{(i)} x^{(i)}}{\sum_{i=1}^n w_l^{(i)}},$$

- $\phi$ 에 대해서 최대화 -  $\phi$ 에 의존하는 항만 남겨둔다.

$$\sum_{i=1}^n \sum_{j=1}^k w_j^{(i)} \log \phi_j.$$

이 때,  $\phi_j$ 는 제약조건  $\sum_{j=1}^k \phi_j = 1$ 이 있기 때문에 라그랑지안으로 풀면 다음과 같다.

$$\mathcal{L}(\phi) = \sum_{i=1}^n \sum_{j=1}^k w_j^{(i)} \log \phi_j + \beta \left( \sum_{j=1}^k \phi_j - 1 \right),$$

$$\frac{\partial}{\partial \phi_j} \mathcal{L}(\phi) = \sum_{i=1}^n \frac{w_j^{(i)}}{\phi_j} + \beta \qquad \phi_j = \frac{\sum_{i=1}^n w_j^{(i)}}{-\beta}$$

## Factor Analysis

$x^{(i)} \in \mathbb{R}^d$  가 가우시안 혼합 구조를 띠 때, 주로 EM 알고리즘을 통해 혼합 모델을 적합할 수 있다.  
 단, 이는 우리의 training set의 크기  $n$ 이 데이터 셋의 차원  $d$ 보다 큰 경우이다.

그렇다면  $d \gg n$ 의 경우를 고려해보자.

이런 경우는 혼합 가우시안을 고사하고 단일 가우시안 모델을 적합하기도 힘들다.

이는  $n$ 개의 데이터들이  $\mathbb{R}^d$ 의 subspace를 span하기 때문이다.

만약 가우시안 모델을 적합한다고 할 때, MLE을 이용한 추정값은 다음과 같다.


$$\mu = \frac{1}{n} \sum_{i=1}^n x^{(i)}$$

$$\Sigma = \frac{1}{n} \sum_{i=1}^n (x^{(i)} - \mu)(x^{(i)} - \mu)^T$$

다만,  $\Sigma$  가 singular, 즉,  $\Sigma^{-1}$  값이 존재하지 않기 때문에,  $1/|\Sigma|^{1/2} = 1/0$ 이 되고,  
 multivariate Gaussian distribution을 계산할 수 없다.

이를 일반화하자면, 어느정도로  $n \gg d$ 가 성립하지 않는다면, mle를 통한 추정값은 영... 좋지 않을 것이다.

정말 눈물이 앞을 가린다



이렇게 적은 데이터셋으로 인해 발생하는 문제를 해결하는 방법으로는  
 첫째, **covariance term**  $\Sigma$ 에 제약 조건을 주는 방법 (후술하겠지만 영 시원찮다)  
 둘째, **EM 알고리즘**을 통해 **Factor Analysis**를 진행하는 방법이 있다.

## Restrictions of $\Sigma$

1. Diagonal covariance matrix

$$\Sigma_{jj} = \frac{1}{n} \sum_{i=1}^n (x_j^{(i)} - \mu_j)^2$$

첫번째 옵션은 시그마를 대각행렬로 제한하는 것이다.

2. Diagonal covariance matrix & diagonal entries must all be equal

$$\sigma^2 = \frac{1}{nd} \sum_{j=1}^d \sum_{i=1}^n (x_j^{(i)} - \mu_j)^2$$

즉,  $\Sigma = \sigma^2 I$  인 경우 이다. 이 경우 gaussian의 contours는 동그라미 모양이다.

위의 두 방법을 이용해 제약규칙을 준다면, 우리는  $n \geq 2$  일 때 non-singular한  $\Sigma$ 를 얻는다.

하지만,

$\Sigma$ 에 제약조건을 주는 것은 서로 다른 변량  $x_i, x_j$  간 **상관관계가 없고 독립인** 것으로 간주하고 모델링하는 것이다. 즉, 데이터의 정보를 어느 정도 잃는 것이라고 볼 수 있다.

만약 우리가 두 변수간 흥미로운 상관관계를 알아내고 싶다면, 이렇게  $\Sigma$ 에 제약조건을 주는 방법은 썩 좋은 방법이 아니다. 그렇다면,  $\Sigma$ 에 제약조건을 주지 않고, 변수 간 상관관계를 알 수 있는 요인 분석에 대해 알아보도록 하자.

## Marginals and conditionals of Gaussians

요인분석에 대해 본격적으로 알아보기에 앞서 marginals and conditionals of Gaussians에 대해 알아보자.

다음과 같은 multivariate gaussian distribution이 있다고 하자.

$$x \sim \mathcal{N}(\mu, \Sigma)$$

$$x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}, \mu = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \Sigma = \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix}$$

- $x_1 \in \mathbb{R}^r, x_2 \in \mathbb{R}^s$  and  $x \in \mathbb{R}^{r+s}$
- $\mu_1 \in \mathbb{R}^r, \mu_2 \in \mathbb{R}^s, \Sigma_{11} \in \mathbb{R}^{r \times r}, \Sigma_{12} \in \mathbb{R}^{r \times s}$
- covariance matrices are symmetric  $\rightarrow \Sigma_{12} = \Sigma_{21}^T$

이 때,

$$\begin{aligned} Cov(x) &= \Sigma \\ &= E[(x - \mu)(x - \mu)^T] \\ &= E\left[\begin{pmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{pmatrix} \begin{pmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{pmatrix}^T\right] \\ &= E\begin{bmatrix} (x_1 - \mu_1)(x_1 - \mu_1)^T & (x_1 - \mu_1)(x_2 - \mu_2)^T \\ (x_2 - \mu_2)(x_1 - \mu_1)^T & (x_2 - \mu_2)(x_2 - \mu_2)^T \end{bmatrix} \end{aligned}$$

1. marginal distribution of  $x_1$  :  $x_1 \sim \mathcal{N}(\mu_1, \Sigma_{11})$

2. conditional distribution :  $x_1|x_2 \sim \mathcal{N}(\mu_{1|2}, \Sigma_{1|2})$

- $\mu_{1|2} = \mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(x_2 - \mu_2)$
- $\Sigma_{1|2} = \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}$

## The Factor analysis model

### 파라미터 설명

우리가 관심있는 것은 joint distribution  $p(x, z) = p(x|z)p(z)$ 이다.

이 때,  $z \in \mathbb{R}^K$ 는 latent random variable이다.

$$z \sim \mathcal{N}(0, I)$$

$$x|z \sim \mathcal{N}(\mu + \Lambda z, \Psi)$$

- $\mu \in \mathbb{R}^{d \times d}, \Lambda \in \mathbb{R}^{d \times k}, \Psi \in \mathbb{R}^{d \times k}$
- $k < d$  ( $k$ 는 데이터 셋의 개수)
  - 데이터 셋  $x^{(i)}$ 가  $k$  차원의 다변량 가우시안 분포  $z^{(i)}$ 에서 샘플링되어서 생성됨
  - $\mu + \Lambda z^{(i)}$  연산  $\rightarrow \mathbb{R}^d$ 차원의 아핀 공간으로 매핑
  - covariance
  - $\Psi$  noise를 추가

이를 바탕으로 factor analysis 모델을 재정의하면 다음과 같다.

$$z \sim \mathcal{N}(0, I)$$

$$\epsilon \sim \mathcal{N}(0, \Psi)$$

$$x = \mu + \Lambda z + \epsilon$$

이 때,  $\epsilon$ 과  $z$ 는 독립이다.

## Joint Gaussian distribution of $z$ and $x$

이제 이 요인분석 모델이 정확히 어떤 분포를 띄는지 정의하자.

확률변수  $z$ 와  $x$ 는 joint Gaussian distribution을 띈다.

$$\begin{bmatrix} z \\ x \end{bmatrix} \sim \mathcal{N}(\mu_{zx}, \Sigma)$$

$$\Sigma = \begin{bmatrix} \Sigma_{zz} & \Sigma_{zx} \\ \Sigma_{xz} & \Sigma_{xx} \end{bmatrix}$$

이제  $\mu_{zx}$ 와  $\Sigma$ 를 구해보자.

1.  $\mu_{zx}$

$$\begin{aligned} E[x] &= E[\mu + \Lambda z + \epsilon] \\ &= \mu + \Lambda E[z] + E[\epsilon] \\ &= \mu \end{aligned}$$

이기 때문에,  $\mu_{zx}$ 는 다음과 같다. ( $\because E[z] = 0$ )

$$\mu_{zx} = \begin{bmatrix} \vec{0} \\ \mu \end{bmatrix}$$

2.  $\Sigma$ : 각각  $\Sigma_{zz}, \Sigma_{zx}, \Sigma_{xx}$ 를 구해보자

- $\Sigma_{zz} = E[(z - E[z])(z - E[z])^T] = I$  ( $\because z \sim \mathcal{N}(0, I)$ )

- $\Sigma_{zx} = E[(z - E[z])(x - E[x])^T]$

$$\begin{aligned} E[(z - E[z])(x - E[x])^T] &= E[z(\mu + \Lambda z + \epsilon - \mu)^T] \\ &= E[zz^T]\Lambda^T + E[z\epsilon^T] \\ &= \Lambda^T \end{aligned}$$

- $\Sigma_{xx} = E[(x - E[x])(x - E[x])^T]$

$$\begin{aligned} E[(x - E[x])(x - E[x])^T] &= E[(\mu + \Lambda z + \epsilon - \mu)(\mu + \Lambda z + \epsilon - \mu)^T] \\ &= E[\Lambda zz^T \Lambda^T + \epsilon z^T \Lambda^T + \Lambda z \epsilon^T + \epsilon \epsilon^T] \\ &= \Lambda E[zz^T] \Lambda^T + E[\epsilon \epsilon^T] \\ &= \Lambda \Lambda^T + \Psi \end{aligned}$$

3. 이제 다시 합쳐보자!

$$\begin{bmatrix} z \\ x \end{bmatrix} \sim \mathcal{N}\left(\begin{bmatrix} \vec{0} \\ \mu \end{bmatrix}, \begin{bmatrix} I & \Lambda^T \\ \Lambda & \Lambda \Lambda^T + \Psi \end{bmatrix}\right)$$

이를 통해, 우리는  $x$ 의 marginal 분포가  $\sim \mathcal{N}(\mu, \Lambda \Lambda^T + \Psi)$ 를 따른다는 것을 알 수 있다.

주어진 파라미터로 log-likelihood를 적으면 다음과 같다.

$$\ell(\mu, \Lambda, \Psi) = \log \prod_{i=1}^n \frac{1}{(2\pi)^{d/2} |\Lambda \Lambda^T + \Psi|^{1/2}} \exp\left(-\frac{1}{2}(x^{(i)} - \mu)^T (\Lambda \Lambda^T + \Psi)^{-1} (x^{(i)} - \mu)\right)$$